

--

Linear Algebra

1. (15 pts) A symmetric matrix A over \mathbb{R} is called *positive semidefinite* (PSD) if for every vector \mathbf{v} , $\mathbf{v}^T A \mathbf{v} \geq 0$.

- (a) Show that a symmetric matrix A is PSD if and only if it can be written as $A = XX^T$, if and only if all of its eigenvalues are non-negative.

Hint: Recall that a real symmetric matrix A can be decomposed as $A = QDQ^T$, where Q is an orthogonal matrix whose columns are eigenvectors of A and D is a diagonal matrix with eigenvalues of A as its diagonal elements.

- (b) Show that for all $\alpha, \beta \geq 0$ and PSD matrices $A, B \in \mathbb{R}^{n \times n}$, the matrix $\alpha A + \beta B$ is also PSD. Does this mean that the set of all $n \times n$ PSD matrices over \mathbb{R} is a vector space over \mathbb{R} ?

(2) 4.00

задачה 2:

$$\forall \mathbf{v}, \mathbf{v}^T A \mathbf{v} \geq 0 \quad (1)$$

$$A = XX^T \quad (2)$$

$$A \text{ סדר } \alpha_i - \beta_i \quad \forall i \quad \alpha_i \geq 0 \quad (3)$$

כלומר $\alpha_i \geq 0 \Rightarrow (1) \Rightarrow (2) \Rightarrow (3)$ רעיון שולחן וריהוק: $\mathbf{y} = X\mathbf{v}$ ו $\mathbf{y}^T \mathbf{y} = \mathbf{v}^T A \mathbf{v}$

$$\mathbf{v}^T A \mathbf{v} = \mathbf{v}^T X X^T \mathbf{v} = (\mathbf{X}^T \mathbf{v})^T \mathbf{X}^T \mathbf{v}$$

$$\mathbf{v}^T A \mathbf{v} = \|\mathbf{y}\|_2^2 \geq 0$$

$$\mathbf{y}^T \mathbf{y} = \mathbf{v}^T X^T X \mathbf{v} = \mathbf{v}^T \mathbf{y} = \mathbf{v}^T A \mathbf{v} \geq 0 \quad (\text{מכיוון })$$

כלומר $(2) \Rightarrow (1)$ נניח שקיים $\mathbf{v}_1, \dots, \mathbf{v}_n$ כך שה $\alpha_i \geq 0$. (1 מוכיח $(1) \Rightarrow (2)$)בנוסף $A_{n \times n}$ הוא מושג:

$$A \mathbf{v}_i = \alpha_i \mathbf{v}_i$$

$$\mathbf{v}_i^T A \mathbf{v}_i = \mathbf{v}_i^T \alpha_i \mathbf{v}_i = \alpha_i \mathbf{v}_i^T \mathbf{v}_i = \alpha_i \|\mathbf{v}_i\|_2^2$$

הוכיחו $v_i^T A v_i \geq 0$ נסsat מתקיימת (1) ו(2)

$$\forall i \quad \underbrace{\|v_i\|_2}_{\geq 0}^2 \geq 0 \Rightarrow \forall i \geq 0$$

. (1) \Rightarrow (3)

נזכיר $A = Q D Q^T$ מינימום כרך 10.2.1

$$Q = \begin{pmatrix} | & | \\ v_1 & \dots & v_n \\ | & | \end{pmatrix} \quad D = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}$$

כזכור, $A_{n \times n}$ הוא מושג כפונקציונלי $\lambda_1, \dots, \lambda_n | v_1, \dots, v_n$

$$A = \begin{pmatrix} | & | \\ v_1 & \dots & v_n \\ | & | \end{pmatrix}_{n \times n} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}_{n \times n} \begin{pmatrix} -v_1 \\ \vdots \\ -v_n \end{pmatrix}_{n \times n}$$

הוכיחו $P = P^T$, P, P^T מושגים כפונקציונליים

$$D = \underbrace{\begin{pmatrix} \lambda_1 & & 0 \\ 0 & \lambda_n \end{pmatrix}}_P \underbrace{\begin{pmatrix} \sqrt{\lambda_1} & & 0 \\ 0 & \sqrt{\lambda_n} \end{pmatrix}}_{P^T} = \begin{pmatrix} \lambda_1 & & 0 \\ 0 & \lambda_n \end{pmatrix}$$

הוכיחו: P, P^T מושגים כפונקציונליים. $\lambda_i \geq 0 \Rightarrow \sqrt{\lambda_i} \geq 0$.

$$A = Q P P^T Q^T = (QP)^T \cdot (QP)$$

$$A = X X^T$$

הוכיחו $QP = X$ מינימום כרך 10.2.1

$(3 \Rightarrow 2 \Rightarrow 1 \Rightarrow (3 \Rightarrow 2 \text{ and } 3))$

גוכפ' תוצאה. נתקן "

$$\begin{array}{c} A \text{ PSD} \iff \\ (1) \quad \underbrace{A = XX^T}_{(2)} \iff \underbrace{\forall i, x_i \geq 0, A_{ii} = x_i^2}_{(3)} \end{array}$$

כבר

ב)

כש תחנו $A, B \in \mathbb{R}^{n \times n}$ PSD ו $\alpha A + \beta B$ חיובי סימטרי. (הוכיחו).

ונרמז כפיג' $\alpha, \beta \geq 0$ ו $\alpha A + \beta B$ חיובי סימטרי.

נוכיח $\alpha A + \beta B$ חיובי סימטרי.

כינד ארכ' ו

$$\begin{aligned} V^T(\alpha A + \beta B)V &= V^T(\alpha Av + \beta Bv) = V^T\alpha Av + V^T\beta Bv \\ &= \alpha V^TAv + \beta V^T Bv \end{aligned}$$

: SK PSD $\vdash A, B \in \mathbb{R}^n$

$$V^TAv \geq 0, V^TBv \geq 0$$

הוכיח $\alpha, \beta \geq 0$

$$\begin{matrix} \alpha V^TAv + \beta V^TBv \\ \geq 0 \quad \geq 0 \quad \geq 0 \quad \geq 0 \end{matrix}$$

ב) ג' נ' ג'

$$V^T(\alpha A + \beta B)V \geq 0$$

. PSD $\vdash \alpha A + \beta B \geq 0$

הנובע מכך כי כל שוקולן של A הוא נורמלית אם $A \in \mathbb{R}^{n \times n}$, A הוא PSD

לפיכך גם $-A$ הוא נורמלית.

A הוא PSD אם ורק אם $A^T A$ הוא PSD.

אנו נראה (F1) $\forall v \in \mathbb{R}^n$ $v^T (-A)v \leq 0$.

$$A_v = \lambda v \Rightarrow (-A)v = (-\lambda)v \Rightarrow v^T (-A)v = v^T (-\lambda)v$$

$$\Rightarrow v^T (-A)v = \underbrace{(-\lambda)}_{<0} \underbrace{v^T v}_{>0} < 0$$

הוכחה:

$$-\lambda < 0 \text{ ו } v^T v > 0$$

$$v^T v \geq 0 \Leftrightarrow \|v\|_2^2 \geq 0$$

טנאי קיינן $\alpha A^T v \leq 0$ כאשר $\alpha \in \mathbb{R}$ אם $v^T (\alpha A)v \leq 0$

$\alpha \geq 0$ $\Rightarrow \alpha A^T v \leq 0$ $\Rightarrow v^T (\alpha A)v \leq 0$ $\Rightarrow v^T A^T v \leq 0$ $\Rightarrow A^T v \leq 0$

הנובע מה הטענה ש $v^T A^T v \leq 0 \Rightarrow A^T v \leq 0$.

Calculus and Probability

1. (15 pts) Let X_1, \dots, X_n be i.i.d $U([0, 1])$ (uniform) continuous random variables. Let $Y = \max(X_1, \dots, X_n)$.

(a) What is the PDF of Y ? Write the mathematical formula and plot the PDF as well.
Compute $\mathbb{E}[Y]$ and $\text{Var}[Y]$ - how do they behave as a function of n as n grows large?

(b) (No need to submit) Verify your answer empirically using Python.

: Y ፩ CDF ጉኑ ስራን ይሆን

$$F_Y(y) = P(Y \leq y) = P(\max(X_1, \dots, X_n) \leq y)$$

$$= P(X_1 \leq y, \dots, X_n \leq y) = \prod_{i=1}^n P(X_i \leq y) = \prod_{i=1}^n F_{X_i}(y)$$

$$= (F_{X_i}(y))^n$$

: ከዚ $X_1, \dots, X_n \sim U(0, 1)$ ይሆን

$$F_{X_i}(y) = \begin{cases} 0 & y < 0 \\ x & 0 \leq y \leq 1 \\ 1 & y > 1 \end{cases}$$

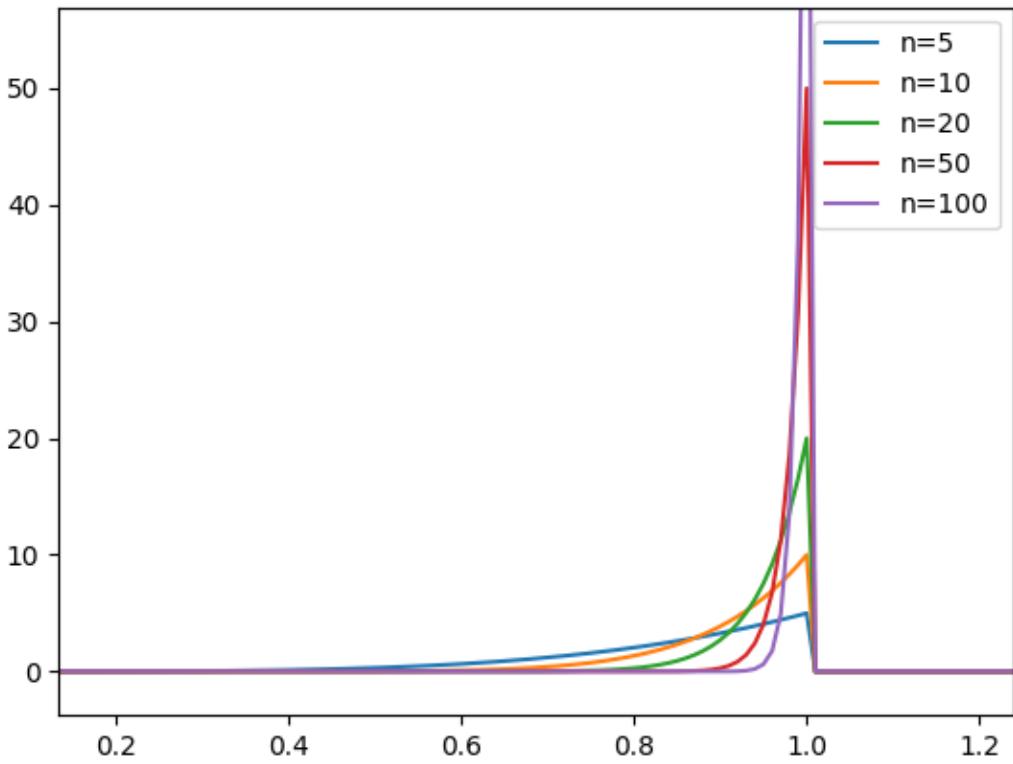
: PDF

$$F_Y(y) = \begin{cases} 0 & y < 0 \\ x^n & 0 \leq y \leq 1 \\ 1 & y > 1 \end{cases}$$

: የዚ, CDF ጉኑ ነው እና የዚ PDF ይሆን ይሆን

$$f_Y(y) = \begin{cases} 0 & y < 0 \\ ny^{n-1} & 0 \leq y \leq 1 \\ 0 & y > 1 \end{cases}$$

plot:



כל אחד מכך נזקיף בפ. גודל

$$E[y] = \int_0^1 y f(y) dy = \int_0^1 y \cdot ny^{n-1} dy = \int_0^1 ny^n dy$$

$$= n \cdot \frac{y^{n+1}}{n+1} \Big|_0^1 = n \left[\frac{1}{n+1} - \frac{0}{n+1} \right] = \frac{n}{n+1}$$

$$\lim_{n \rightarrow \infty} \frac{n}{n+1} = \lim_{n \rightarrow \infty} \frac{\frac{n}{n}}{\frac{n}{n} + \frac{1}{n}} = \lim_{n \rightarrow \infty} \frac{1}{1+0} = 1$$

(הו יפה פה מזין לך נסחף) סביר לנו $E[y] = \frac{n}{n+1}$ פונקציית
הנגילה שפיה 1. הינה
היפוך של פונקציית גודלה:

$$\text{Var}(y) = E[y^2] - (E[y])^2 \quad \text{⊗}$$

$$E[y^2] = \int_0^1 y^2 f(y) dy = \int_0^1 y^2 ny^{n-1} dy = n \int_0^1 y^{n+1} dy$$

$$= n \cdot \frac{y^{n+2}}{n+2} \Big|_0^1 = n \left[\frac{1}{n+2} - \frac{0}{n+2} \right] = \frac{n}{n+2}$$

$$E[y] = \frac{n}{n+1}$$

כואיל נזקיף

$$\text{Var}(y) = \frac{n}{n+2} - \left(\frac{n}{n+1} \right)^2 = \frac{n}{n+2} - \frac{n^2}{n^2 + 2n + 1}$$

לצ'כ טרנסFORM

$$\lim_{n \rightarrow \infty} \left(\frac{n}{n+2} - \frac{n^2}{n^2 + 2n + 1} \right) = \lim_{n \rightarrow \infty} \frac{n}{n+2} - \lim_{n \rightarrow \infty} \frac{n^2}{n^2 + 2n + 1}$$

$$= \lim_{n \rightarrow \infty} \frac{\frac{n}{n}}{\frac{n+2}{n+2}} - \lim_{n \rightarrow \infty} \frac{\frac{n^2}{n^2}}{\frac{n^2 + 2n + 1}{n^2 + 2n + 1}}$$

$$= \lim_{n \rightarrow \infty} \frac{1}{1} - \lim_{n \rightarrow \infty} \frac{1}{1} = 1 - 1 = 0$$

$$\text{var}(Y) = \frac{n}{n+2} - \frac{n^2}{n^2 + 2n + 1}$$

ולא נetag בפונקציית פירסום

כבר נזכיר

Optimal Classifiers and Decision Rules

1. (15 pts)

- (a) Let X and Y be random variables where Y can take values in $\mathcal{Y} = \{1, \dots, L\}$. Let ℓ_{0-1} be the 0-1 loss function defined in class. Show that $h = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \mathbb{E}[\ell_{0-1}(Y, f(X))]$ is given by

$$h(x) = \arg \max_{i \in \mathcal{Y}} \mathbb{P}[Y = i | X = x]$$

0-1 loss הינה מינימלית אזי נבחר $h(x)$

$$\arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \mathbb{E}[\ell_{0-1}(Y, f(X))]$$

$$= \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \sum_{x, y} P(X=x, Y=y) \cdot \ell_{0-1}(y, f(x))$$

זהו אפסון כפונקציית האמצע של $P(Y=i)$

$$\sum_{i=1}^L P(X=x, Y=i) \cdot \ell_{0-1}(i, f(x))$$

ניחסו לה נולו

$$= \sum_{i=1}^L P(X=x) \cdot P(Y=i | X=x) \cdot \ell_{0-1}(i, f(x))$$

$$= P(X=x) \cdot \sum_{i=1}^L P(Y=i | X=x) \cdot \ell_{0-1}(i, f(x))$$

כזו פונקציית loss מינימלית

$$\ell_{0-1}(k, k) = 0, \quad \ell_{0-1}(k, j) = 1 \quad j \neq k$$

לפיכך $\ell_{0-1}(i, f(x)) = 0$ אם $f(x) = i$ במקרה פלוי $\ell_{0-1}(i, f(x)) = 1$ במקרה $f(x) \neq i$

$$P(X=\hat{x}) \cdot \sum_{i=1}^L P(Y=i | X=\hat{x}) \cdot b_{0-i}(i, f(\hat{x}))$$

$$= P(X=\hat{x}) \cdot \sum_{\substack{i \\ i \neq f(\hat{x})}} P(Y=i | X=\hat{x})$$

כשהם נסרים $f(\hat{x}) = k$ מהתוצאות. על מנת שפונקציית הסתברות תישמר על הדרישה שפונקציית הסתברות תהיה כפולה של פונקציית הסתברות כפולה. נסרים את \star ונותן כפולה היפרbole. בדרכו נזקק ל-

$$h(\hat{x}) = \arg \max_{k \in Y = \{1, \dots, L\}} P(Y=k | X=\hat{x})$$

- (b) Let X and Y be random variables where Y can take values in $\mathcal{Y} = \{0, 1\}$. Let Δ be the following asymmetric loss function:

$$\Delta(y, \hat{y}) = \begin{cases} 0 & y = \hat{y} \\ a & y = 0, \hat{y} = 1 \\ b & y = 1, \hat{y} = 0, \end{cases}$$

where $a, b \in (0, 1]$ (note that this loss function generalizes the 0-1 loss defined in class). Compute the optimal decision rule h for the loss function Δ , i.e. the decision rule which satisfies:

$$h = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \mathbb{E} [\Delta(Y, f(X))]$$

$$h = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} L(x) = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \mathbb{E} [\Delta(Y, f(x))]$$

$$= \arg \min_{f: \mathcal{X} \rightarrow \mathcal{Y}} \sum_{x,y} P(x=x, y=y) \cdot \Delta(y, f(x))$$

הנור אומע כפכוף נורא גורם

$$\sum_{i=0}^1 P(x=\hat{x} | y=i) \cdot \Delta(y, f(x))$$

: מינימום

$$= P(x=\hat{x}, y=0) \cdot \Delta(0, f(\hat{x})) + P(x=\hat{x}, y=1) \cdot \Delta(1, f(\hat{x}))$$

ונור אומע כפכוף נורא גורם

$$= P(x=\hat{x}) \cdot P(y=0 | x=\hat{x}) \cdot \Delta(0, f(\hat{x}))$$

$$+ P(x=\hat{x}) \cdot P(y=1 | x=\hat{x}) \cdot \Delta(1, f(\hat{x}))$$

$$\textcircled{*} = P(x=\hat{x}) [P(y=0 | x=\hat{x}) \cdot \Delta(0, f(\hat{x})) + P(y=1 | x=\hat{x}) \cdot \Delta(1, f(\hat{x}))]$$

כגון נור אומע כפכוף נורא גורם . 0,1 פונקציית $f(x)$ נור אומע כפכוף נורא גורם . 0,1 פונקציית $f(x)$

$$\Delta(0, f(x)) = \Delta(0, 0) = 0$$

לפיכך $P(Y=0|X=\hat{x}) \Delta(0, f(\hat{x}))$ מילא את הדרישה

$$\Delta(1, f(x)) = \Delta(1, 1) = b$$

וכן דרכן נקבעו מאובני החלטה

$$P(X=\hat{x}) \cdot P(Y=0|X=\hat{x}) \cdot b$$

לפיכך הבחירה הנכונה היא $f(x)=1$ ו $\Delta(1, f(\hat{x})) = b$

$$\Delta(0, f(x)) = \Delta(0, 1) = a$$

$$\Delta(1, f(x)) = \Delta(1, 1) = 0$$

כך דרכן

מילא את הדרישה $P(Y=1|X=\hat{x}) \cdot \Delta(1, f(\hat{x}))$

וכן דרכן נקבעו מאובני החלטה

$$P(X=\hat{x}) \cdot P(Y=0|X=\hat{x}) \cdot a$$

הנולות עשויה לא לזרום מעתה \oplus מילא את הדרישה $P(Y=1|X=\hat{x}) \cdot \Delta(1, f(\hat{x}))$ ו $P(Y=0|X=\hat{x}) \cdot \Delta(0, f(\hat{x}))$

$$h(\hat{x}) = 1 \iff P(Y=1|X=\hat{x}) \cdot b \geq P(Y=0|X=\hat{x}) \cdot a$$

$$\iff \frac{P(Y=1|X=\hat{x})}{P(Y=0|X=\hat{x})} \geq \frac{a}{b}$$

$$h(\hat{x}) = \begin{cases} 1 & \frac{P(Y=1|X=\hat{x})}{P(Y=0|X=\hat{x})} \geq \frac{a}{b} \\ 0 & \frac{P(Y=1|X=\hat{x})}{P(Y=0|X=\hat{x})} < \frac{a}{b} \end{cases}$$

2. (15 pts) Let X and Y be random variables where X can take values in some set \mathcal{X} and Y can take values in $\mathcal{Y} = \{0, 1\}$ (i.e. binary label space). Assume we wish to find a predictor $h : \mathcal{X} \rightarrow [0, 1]$ (note that the hypothesis can output any number between 0 and 1) which minimizes $\mathbb{E}[\Delta_{\log}(Y, h(X))]$, where Δ_{\log} is the following loss function known as the *log-loss*:

$$\Delta_{\log}(y, \hat{y}) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y}).$$

Find the predictor $h : \mathcal{X} \rightarrow [0, 1]$ which minimizes $\mathbb{E}[\Delta_{\log}(Y, h(X))]$.

Note: This loss function may seem odd at first, but it is very important and we'll discuss it further in the future.

: Δ_{\log} גודל פונקציונלי של הLoss

$$\underset{h: X \rightarrow [0, 1]}{\operatorname{argmin}} \mathbb{E} [\Delta_{\log}(Y, h(X))]$$

$$= \underset{h: X \rightarrow [0, 1]}{\operatorname{argmin}} \sum_{x, y} p(x=x, y=y) \cdot \Delta_{\log}(y, h(x))$$

זהו שטח מילוי פונקציונלי נספח כפוי
מהתפלגות $p(y=0, 1)$

$$P(X=\hat{x}, Y=0) \cdot \Delta_{\log}(0, h(\hat{x})) + P(X=\hat{x}, Y=1) \cdot \Delta_{\log}(1, h(\hat{x}))$$

נובע מכך: $\Delta_{\log}(0, h(\hat{x}))$

$$\begin{aligned} & P(X=\hat{x}) [P(Y=0 | X=\hat{x}) \cdot \Delta_{\log}(0, h(\hat{x})) \\ & + P(Y=1 | X=\hat{x}) \cdot \Delta_{\log}(1, h(\hat{x}))] \end{aligned}$$

מגדר Δ_{\log} מוגדר

$$\Delta_{\log}(0, h(\hat{x})) = 0 - (1-0) \log(1-h(\hat{x}))$$

$$= -\log(1-h(x))$$

$$\Delta \log(1, h(x)) = -\log(h(x)) - 0 = -\log(h(x))$$

לפ' נס' \star

$$P(X=\hat{x}) [P(Y=0|X=\hat{x}) \cdot (-\log(1-h(x))) + P(Y=1|X=\hat{x}) \cdot (-\log(h(x)))]$$

נראה מכאן כי $P(Y=0|X=\hat{x}) = P(Y=1|X=\hat{x})$.

לפ' נס' \star

$$P(X=\hat{x}) [P(Y=0|X=\hat{x}) \cdot \left(\frac{1}{1-h(x)}\right) + P(Y=1|X=\hat{x}) \cdot \left(\frac{1}{h(x)}\right)] = 0$$

מונע מכאן כי $h(\hat{x})=1$ או $h(\hat{x})=0$.

אם $h(\hat{x})=0$ פ' נס' \star : מילוי בהריבויים.

ולא, $h(\hat{x})=0$ כי $P(Y=0|X=\hat{x}) > P(Y=1|X=\hat{x})$.

$P(Y=1|X=\hat{x}) > P(Y=0|X=\hat{x})$ מילוי בהריבויים.

בנוסף, $h(\hat{x})=1$ כי $P(Y=0|X=\hat{x}) = P(Y=1|X=\hat{x})$.

בנוסף, $h(\hat{x})=1$ כי $P(Y=0|X=\hat{x}) = P(Y=1|X=\hat{x})$.

$$P(Y=0|X=\hat{x}) \left(\frac{1}{1-h(\hat{x})}\right) + P(Y=1|X=\hat{x}) \left(\frac{1}{h(\hat{x})}\right) = 0$$

$$\frac{P(Y=0|X=\hat{x})}{1-h(\hat{x})} = \frac{P(Y=1|X=\hat{x})}{h(\hat{x})}$$

$$1 - h(\hat{x}) = P(Y=0 | X=\hat{x})$$

$$h(\hat{x}) = P(Y=1 | X=\hat{x})$$

$$\frac{1}{h(\hat{x})} - 1 = \frac{P(Y=0 | X=\hat{x})}{P(Y=1 | X=\hat{x})}$$

$$\frac{1}{h(\hat{x})} = 1 + \frac{P(Y=0 | X=\hat{x})}{P(Y=1 | X=\hat{x})}$$

$$\frac{1}{h(\hat{x})} = \frac{P(Y=1 | X=\hat{x})}{P(Y=1 | X=\hat{x})} + \frac{P(Y=0 | X=\hat{x})}{P(Y=1 | X=\hat{x})}$$

ננו מוכיחו שהיא מוגדרת:

$$\frac{1}{h(\hat{x})} = \frac{1}{P(Y=1 | X=\hat{x})}$$

יש לנו נown הינו $P(Y=1 | X=\hat{x}) < 1$
ולכן $\frac{1}{P(Y=1 | X=\hat{x})} > 1$:

$$P(X=\hat{x}) \left[P(Y=0 | X=\hat{x}) \cdot \left(\frac{1}{1-h(\hat{x})} \right)^2 + P(Y=1 | X=\hat{x}) \cdot \left(\frac{1}{h(\hat{x})^2} \right) \right] > 1$$

וכזה נוכיח ש $h(\hat{x})$

ונown $h(\hat{x}) = P(Y=1 | X=\hat{x})$ וזה רק אומר
שהה כפולה:

$$h(\hat{x}) = \begin{cases} 1 & P(Y=1 | X=\hat{x}) \geq P(Y=0 | X=\hat{x}) \\ 0 & \text{ אחרת} \end{cases}$$

3. (10 pts)

Let X and Y be random variables taking values in $\mathcal{X} = \mathbb{R}$ and $\mathcal{Y} = \{0, 1\}$ respectively, and assume that given $Y = 0$, X is distributed normally with mean μ and variance σ_0^2 , i.e. $X \sim \mathcal{N}(\mu, \sigma_0^2)$, and similarly, given $Y = 1$, $X \sim \mathcal{N}(\mu, \sigma_1^2)$, where $\sigma_0 \neq \sigma_1$. Also assume $\Pr[Y = 1] = p_1$.

Find the optimal decision rule for this distribution and the zero-one loss, i.e. find $h : \mathbb{R} \rightarrow \{0, 1\}$ which minimizes $\mathbb{E}[\ell_{0-1}(Y, h(X))]$ where ℓ_{0-1} is the zero-one loss defined in class (write the decision rule only in terms of $x, \mu, \sigma_0, \sigma_1$ and p_1).

לפנינו מינימיזציה של איבר נזק זר-אחד

$$h = \arg \min_{h: X \rightarrow Y} E [\ell_{0-1}(Y, h(X))]$$

$$= \arg \min_{h: X \rightarrow Y} \sum_{x,y} P(X=x, Y=y) \cdot \ell_{0-1}(y, h(x))$$

הנחנו $X - \mathbb{R}$ ו $Y = \{0, 1\}$

$$\therefore Y = \begin{cases} 0 & \text{if } X \leq \hat{x} \\ 1 & \text{if } X > \hat{x} \end{cases}$$

$$\begin{aligned} & P(X=\hat{x}, Y=0) \cdot \ell_{0-1}(0, h(\hat{x})) \\ & + P(X=\hat{x}, Y=1) \cdot \ell_{0-1}(1, h(\hat{x})) \\ & = P(X=\hat{x}) [P(Y=0|X=\hat{x}) \ell_{0-1}(0, h(\hat{x})) \\ & \quad + P(Y=1|X=\hat{x}) \ell_{0-1}(1, h(\hat{x}))] \end{aligned}$$

$$\ell_{0-1}(0, 0) = 0, \ell_{0-1}(1, 1) = 1$$

ככל ש X גדול יותר מ \hat{x} , אז $P(Y=1|X=\hat{x}) > P(Y=0|X=\hat{x})$

$$h(x) = \begin{cases} 1 & P(Y=1|X=\hat{x}) \geq P(Y=0|X=\hat{x}) \\ 0 & \text{otherwise} \end{cases}$$

כזכור נס. נתקנו $p(Y=1|X=\hat{x}) \geq p(Y=0|X=\hat{x})$
 כי אם נסמן ב- \hat{x}

$$p(Y=1|X=\hat{x}) = \frac{f_X(\hat{x}|Y=1) \cdot p(Y=1)}{f_X(\hat{x})}$$

$$p(Y=0|X=\hat{x}) = \frac{f_X(\hat{x}|Y=0) \cdot p(Y=0)}{f_X(\hat{x})}$$

: סבירו \otimes גנום

$$f_X(x|Y=1) \cdot p(Y=1) \geq f_X(x|Y=0) \cdot p(Y=0)$$

\Leftrightarrow

$$\frac{f_X(x|Y=1)}{f_X(x|Y=0)} \geq \frac{p(Y=0)}{p(Y=1)}$$

\Leftrightarrow

$$\frac{\frac{1}{\sqrt{2\pi\sigma_1^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_1^2}}}{\frac{1}{\sqrt{2\pi\sigma_0^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_0^2}}} > \frac{1-p_1}{p_1}$$

\Leftrightarrow

$$\frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sigma_1} \cdot e^{\left(-\frac{(x-\mu)^2}{2\sigma_1^2} + \frac{(x-\mu)^2}{2\sigma_0^2}\right)} > \frac{1-p_1}{p_1}$$

$$\frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\sigma_0} \cdot \underbrace{\frac{\sigma_0}{\sigma_1}}$$

\Leftrightarrow

$$e^{\left(-\frac{(x-\mu)^2}{2\sigma_1^2} + \frac{(x-\mu)^2}{2\sigma_0^2}\right)} > \frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)$$

ln \approx

$$\left(-\frac{(x-\mu)^2}{2\sigma_1^2} + \frac{(x-\mu)^2}{2\sigma_0^2}\right) > \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right)$$

$$\frac{1}{2}(x-\mu)^2 \cdot \left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}\right) > \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right)$$

$$(x-\mu)^2 \left(\frac{\sigma_1^2 - \sigma_0^2}{\sigma_0^2 \sigma_1^2}\right) > 2 \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right)$$

: $\sigma_1^2 > \sigma_0^2$ $\sigma_1^2 - \sigma_0^2 > 0$ $\sigma_1^2 > \sigma_0^2$ $p_1 < p$

$$(x-\mu)^2 > 2 \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right) \cdot \left(\frac{\sigma_0^2 \sigma_1^2}{\sigma_1^2 - \sigma_0^2}\right)$$

: $\sigma_1^2 < \sigma_0^2$ $\sigma_1^2 - \sigma_0^2 < 0$ $\sigma_1^2 < \sigma_0^2$ $p_1 < p$

$$(x-\mu)^2 < 2 \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right) \cdot \left(\frac{\sigma_0^2 \sigma_1^2}{\sigma_1^2 - \sigma_0^2}\right)$$

: $\sigma_1^2 > \sigma_0^2$ $p_1 < p$

$$h(x) = \begin{cases} 1 & (x-\mu)^2 > 2 \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right) \cdot \left(\frac{\sigma_0^2 \sigma_1^2}{\sigma_1^2 - \sigma_0^2}\right) \\ 0 & \text{sonst} \end{cases}$$

: $\sigma_0^2 > \sigma_1^2$ $p_1 < p$

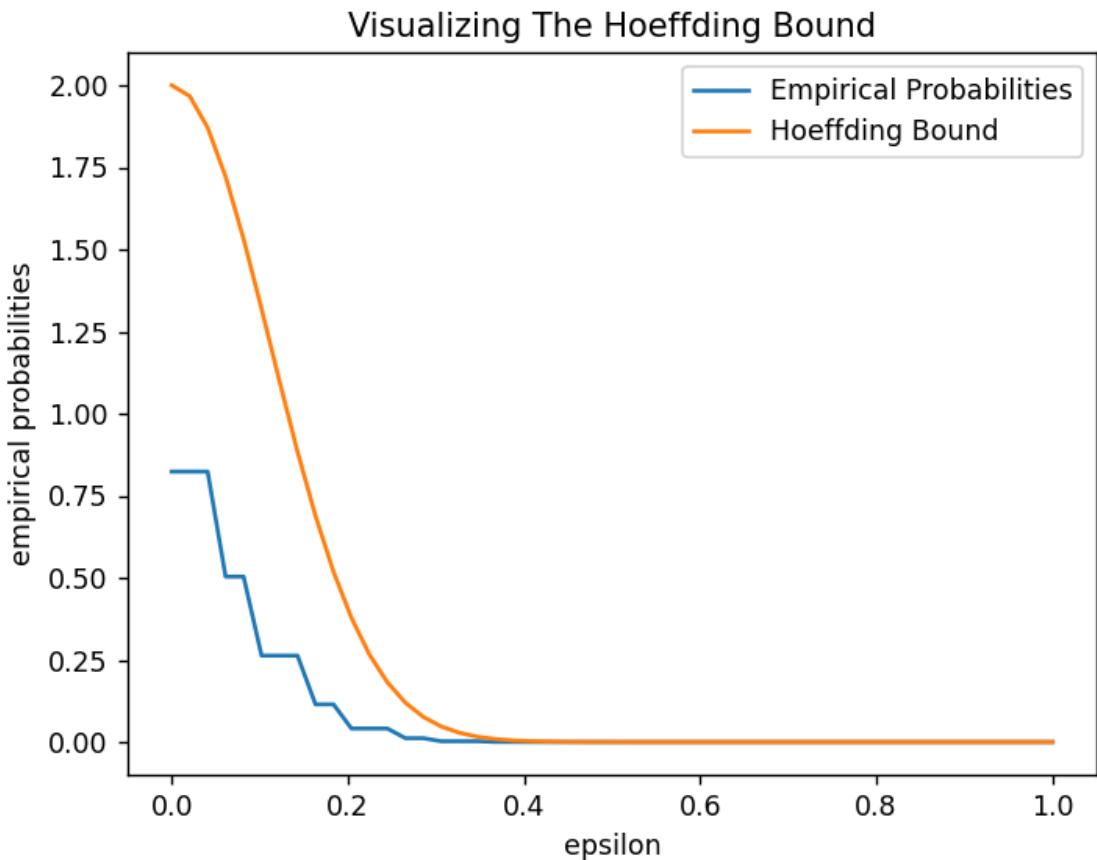
$$h(x) = \begin{cases} 1 & (x-\mu)^2 < 2 \ln \left(\frac{\sigma_1}{\sigma_0} \left(\frac{1-p_1}{p_1}\right)\right) \cdot \left(\frac{\sigma_0^2 \sigma_1^2}{\sigma_1^2 - \sigma_0^2}\right) \\ 0 & \text{sonst} \end{cases}$$

הוכחה ורשות + נספח

1. Visualizing the Hoeffding bound (10 pts).

- Use `numpy` to generate an $N \times n$ matrix of samples from $Bernoulli(1/2)$. Calculate for each row i the empirical mean, $\bar{X}_i = \frac{1}{n} \sum_{j=1}^n X_{i,j}$, where $N = 200000$ and $n = 20$.
- Take 50 values of $\epsilon \in [0, 1]$ (`numpy.linspace(0, 1, 50)`), and calculate the empirical probability that $|\bar{X}_i - 1/2| > \epsilon$. Plot the empirical probability as a function of ϵ .
- Add to your plot the Hoeffding bound of that probability, as a function of ϵ .

Submit your plots (no need to submit code for this question).

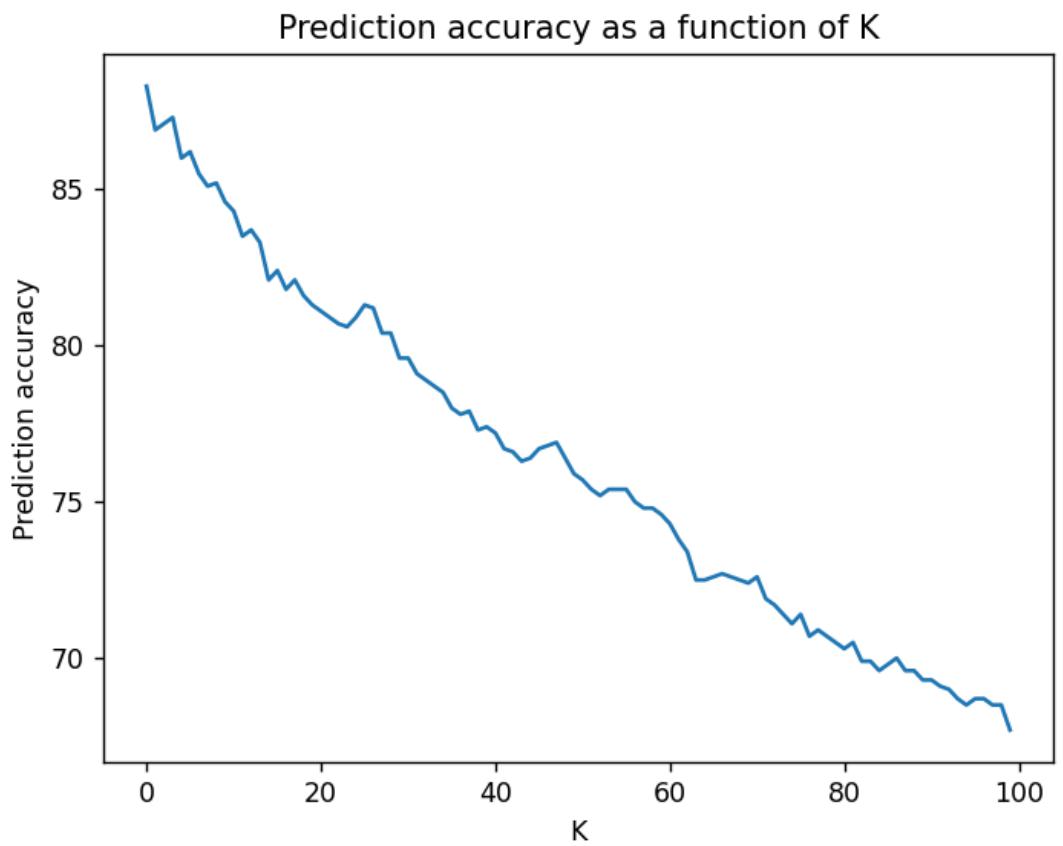


2. Nearest Neighbor (20 pts).

- (b) Run the algorithm using the first $n = 1000$ training images, on each of the test images, using $k = 10$. What is the accuracy of the prediction (i.e. the percentage of correct classifications)? What would you expect from a completely random predictor?

לעומת ה-NN מוגדרת אcurracy כ-
 $\frac{\text{מספר מקרים שטובים}}{\text{מספר מקרים שטובים} + \text{מספר מקרים שטעומים}}$
במקרה של 10 מינוחים, אcurracy יהיה $\frac{1}{10} = 10\%$

- (c) Plot the prediction accuracy as a function of k , for $k = 1, \dots, 100$ and $n = 1000$. Discuss the results. What is the best k ?



ריצת חישובים על מנת לראות כיצד הערך הולך וול. רצף מוגן
בוחנן בפונקציית \min והוא לא נזמין ($\min(1, 0) = 0$). הינה
וילג'ו אובי. נסמן y_{true} כערך האמיתי שנקה יותר סעיפים
כanders. סימן y_{pred} כערך העומד בצד השני של פונקציית \min .
הנתקן סימן y_{pred} נזמין מפונקציית \min רק אם $y_{\text{pred}} < 1$, אך
במקרה שבו $y_{\text{pred}} \geq 1$ פונקציית \min מזמין y_{pred} ולא y_{true} .
במקרה שבו $y_{\text{pred}} < 1$ פונקציית \min מזמין y_{true} ולא y_{pred} .

- (d) Using $k = 1$, run the algorithm on an increasing number of training images. Plot the prediction accuracy as a function of $n = 100, 200, \dots, 5000$. Discuss the results.

